Universidad Tecnológica Ciudad Juárez



Materia: Extracción de Conocimiento en Base de Datos

Actividad: RA - U2

Docente: Barraza Rojas Sueisen Ibeth

Alumno: Ruth Elena Pimienta Nava

Juárez Chihuahua **15/10/2026**

INTRODUCCIÓN

El presente informe académico presenta un modelo analítico de inteligencia de negocios (BI) diseñado para una institución de educación superior. El objetivo central es examinar el rendimiento académico de los estudiantes durante los últimos cinco años con el propósito de optimizar la toma de decisiones estratégicas en materia curricular, evaluar el impacto del desempeño docente, identificar factores de riesgo asociados a la deserción escolar y analizar variables demográficas y de asistencia. Mediante la construcción de un Data Warehouse y un cuadro de mando interactivo (Dashboard), la institución cuenta con una herramienta robusta para responder a interrogantes clave sobre la calidad educativa.

Esquema de data warehouse.

Primero realizamos la separación en excel donde vamos a crear las tablas de dimensiones y la tabla de hechos , con base al excel RA Dataset datos_estudiantes Realizamos una leyenda y con base a esto podemos ordenar mejor nuestras tablas.

A14

	A	B	C	D	E	F
1	**Esquema de Data Warehouse – Análisis Académico Institucional**					
2						
3	**Hoja**	**Tipo de tabla**	**Llave**	**Color**	**Descripción**	
4	**Hechos_Calificaciones**	Tabla de HECHOS	id_hecho		Calificación final y % de asistencia por estudiante, materia, docente, programa y periodo; incluye Estado_Aprobacion (columna calculada)	
5	**Dim_Estudiante**	Dimensión	id_estudiante		Datos del alumno: sexo, edad, municipio y bachillerato de procedencia	
6	**Dim_Materia**	Dimensión	id_materia		Nombre, área de conocimiento y tipo de materia	
7	**Dim_Docente**	Dimensión	id_docente		Nombre, formación y antigüedad del docente	
8	**Dim_Programa**	Dimensión	id_programa		Programa educativo, nivel y modalidad	
9	**Dim_Periodo**	Dimensión	id_periodo		Año, semestre y fechas del periodo	
10						
11	Relaciones: cada dimensión se conecta con Hechos_Calificaciones mediante su llave (uno a muchos, 1:*; filtro de la dimensión hacia los hechos).					
12	Estado_Aprobacion = "Aprobado" si calificacion_final >= 70, de lo contrario "Reprobado" (umbral de 70 asumido; ajustar si la universidad usa otro).					
13						
14						
15						
16						

Tabla dim_estudiante

	A	B	C	D	E	F
1	**id_estudiante**	**nombre_estudiante**	**sexo**	**edad**	**municipio**	**bachillerato_procedencia**
2	E001	Ana Pérez	F	19	Chihuahua	CETis 22
3	E002	Carlos Ruiz	M	20	Juárez	CBTis 128
4	E003	Diana Ríos	F	21	Delicias	COBACH 3
5	E004	Erick Salas	M	22	Parral	CONALEP
6						
7						

Tabla dim_materia

G27

	A	B	C	D	E
1	**id_materia**	**nombre_materia**	**area_conocimiento**	**tipo_materia**	
2	M101	Matemáticas Discretas	Matemáticas	Obligatoria	
3	M102	Programación I	Computación	Obligatoria	
4	M103	Física I	Ciencias	Obligatoria	
5					
6					

Tabla dim_docente

D10

	A	B	C	D	E
1	**id_docente**	**nombre_docente**	**formacion_docente**	**antiguedad_docente**	
2	D001	Mario López	Maestría	10	
3	D002	Laura Gómez	Licenciatura	6	
4	D003	Juan Mendoza	Doctorado	15	
5					

Tabla dim_programa

	A	B	C	D	E
1	id_programa	nombre_programa	nivel_programa	modalidad_programa	
2	P01	Ingeniería en Sistemas	Licenciatura	Escolarizado	
3					

Tabla dim_periodo

	A	B	C	D	E	F
1	id_periodo	anio	semestre	fecha_inicio	fecha_fin	
2	P2021_1	2021	1	10/01/2021	15/06/2021	
3						

Tabla hechos_calificaciones

	A	B	C	D	E	F	G	H	I
1	id_hecho	id_estudiante	id_materia	id_docente	id_programa	id_periodo	calificacion_final	asistencia_pct	Estado_Aprobacion
2	H001	E001	M101	D001	P01	P2021_1	85	90	Aprobado
3	H002	E002	M102	D002	P01	P2021_1	78	80	Aprobado
4	H003	E003	M101	D001	P01	P2021_1	92	95	Aprobado
5	H004	E001	M102	D002	P01	P2021_1	88	85	Aprobado
6	H005	E004	M103	D003	P01	P2021_1	65	70	Reprobado
7									

Tipos y fuentes de datos.

Fuente de datos

- Los datos del análisis provienen del archivo RA_Dataset_datos_estudiantes.csv proporcionado en la actividad, que contiene registros académicos de estudiantes de una universidad: datos del alumno, materia cursada, docente, programa educativo, periodo escolar, calificación final y porcentaje de asistencia.
- Este archivo se procesó en Microsoft Excel, donde se limpió y se separó en tablas de dimensiones y una tabla de hechos, y se guardó como datos_estudiantes_limpios.xlsx. Ese libro es la fuente que se importó a Power BI para construir el modelo y el dashboard.
- Flujo de los datos: **Archivo CSV original → Limpieza y modelado en Excel → Modelo y dashboard en Power BI**

Tipos de datos

Se trabajó con datos estructurados (organizados en filas y columnas) de los siguientes tipos:

Tipo de dato	Campos
Identificadores (texto)	id_estudiante, id_materia, id_docente, id_programa, id_periodo, id_hecho
Categóricos (cualitativos)	sexo, municipio, bachillerato_procedencia, nombre_materia, area_conocimiento, tipo_materia, formacion_docente, nivel_programa, modalidad_programa, Estado_Aprobacion
Numéricos (cuantitativos)	edad, antiguedad_docente, anio, semestre, calificacion_final, asistencia_pct
Fecha	fecha_inicio, fecha_fin

El conjunto de datos es una muestra del caso de estudio: 5 registros de calificaciones de 4 estudiantes, 3 materias y 3 docentes de un programa en un periodo.

Técnicas de limpieza de datos

Se aplicaron las siguientes técnicas sobre el archivo original:

1. Revisión y eliminación de valores nulos: se revisaron todas las columnas en busca de datos faltantes. No se encontraron valores nulos, por lo que no fue necesario eliminar ni rellenar registros.
2. Revisión y eliminación de duplicados: se verificó que no hubiera registros repetidos. No se encontraron filas duplicadas. En las dimensiones se dejó un solo registro por cada llave (por ejemplo, un solo registro por estudiante aunque cursara varias materias).
3. Corrección de errores ortográficos y de formato en textos: se revisaron nombres, municipios, materias y demás campos de texto, y se eliminaron espacios sobrantes al inicio y al final. No se detectaron errores ortográficos.

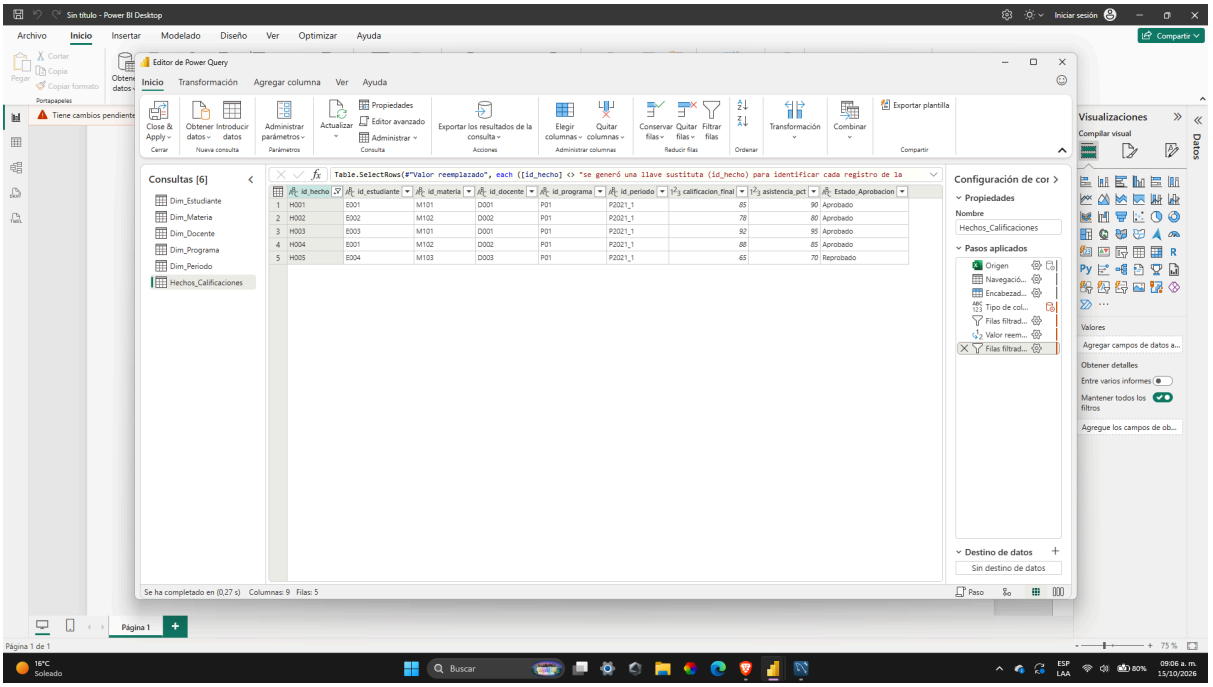
4. Conversión de tipos de datos: las fechas fecha_inicio y fecha_fin venían como texto (dd/mm/aaaa) y se convirtieron a formato de fecha. Las columnas edad, antiguedad_docente, anio, semestre, calificacion_final y asistencia_pct se mantuvieron como números enteros.
5. Normalización del modelo (separación en dimensiones y hechos): se separaron los datos descriptivos en cinco tablas de dimensión (Dim_Estudiante, Dim_Materia, Dim_Docente, Dim_Programa, Dim_Periodo) y se dejó una tabla de hechos con solo las llaves y las medidas, para evitar repetir información.
6. Creación de llave sustituta: se generó id_hecho (H001, H002, ...) para identificar de forma única cada registro de la tabla de hechos.
7. Columna calculada Estado_Aprobacion: se agregó con la regla “Aprobado” si calificacion_final es mayor o igual a 70, y “Reprobado” si es menor. Esto permite analizar el porcentaje de aprobación.
8. Identificación visual de las tablas: cada hoja del Excel se marcó con un color (rojo para hechos y un color distinto para cada dimensión) para reconocerlas fácilmente.
9. Se recorrieron títulos como primera fila en vez de que ocupen la segunda fila

Esta limpieza se aplicó tanto en excel como en PowerBi

Parámetros de configuración del data warehouse.

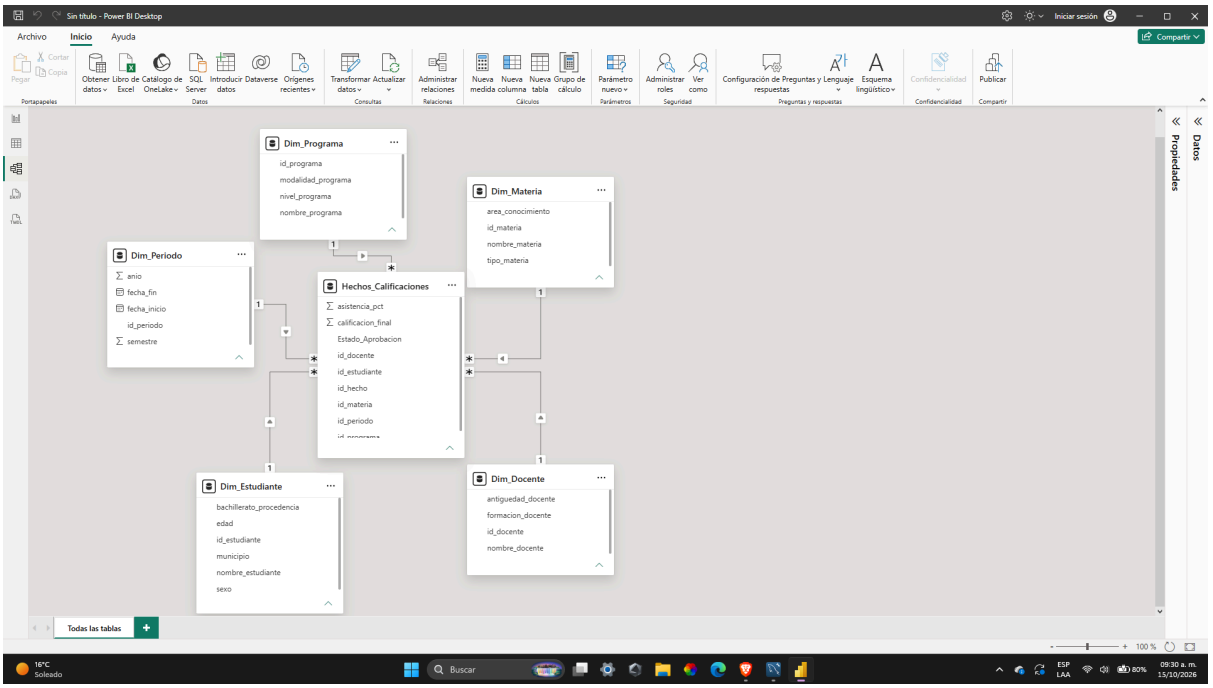
Herramientas utilizadas

- **Microsoft Excel:** para la limpieza inicial de los datos y la separación en tablas de dimensiones y de hechos.
- **Power Query (Power BI):** para la segunda revisión de limpieza (nulos, tipos de datos y promoción de encabezados).
- **Power BI Desktop:** para crear el modelo de datos, las relaciones, las medidas y el dashboard.



Modelo de esquema

Se utilizó un **esquema en estrella**: una tabla de hechos (Hechos_Calificaciones) al centro, conectada con cinco tablas de dimensión (Dim_Estudiante, Dim_Materia, Dim_Docente, Dim_Programa y Dim_Periodo). La tabla de hechos guarda las medidas (calificacion_final y asistencia_pct) y las llaves, mientras que las dimensiones guardan los datos descriptivos.



Relaciones

Todas las relaciones son de uno a muchos (1:*): cada registro de una dimensión puede aparecer en muchos registros de la tabla de hechos, pero cada registro de hechos pertenece a un solo registro de cada dimensión. La dirección del filtro va de la dimensión hacia la tabla de hechos.

Dimensión (lado 1)	Tabla de hechos (lado *)	Campo de relación
Dim_Estudiante	Hechos_Calificaciones	id_estudiante
Dim_Materia	Hechos_Calificaciones	id_materia
Dim_Docente	Hechos_Calificaciones	id_docente
Dim_Programa	Hechos_Calificaciones	id_programa
Dim_Periodo	Hechos_Calificaciones	id_periodo

No se usaron relaciones de muchos a muchos.

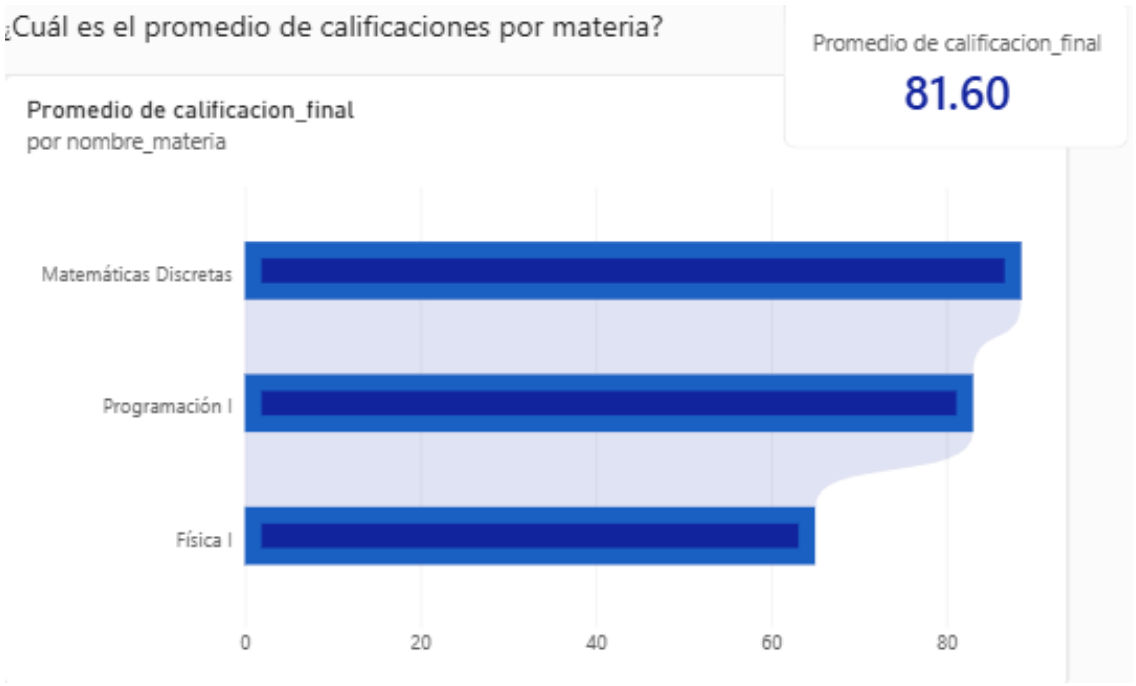
Medidas y visualizaciones

Se usaron promedios de calificacion_final y de asistencia_pct, y recuentos de docentes y municipios. Para cada pregunta se eligió un tipo de gráfica: barras horizontales (promedio por materia y por municipio), columnas (promedio por docente) y dispersión (asistencia contra calificación por estudiante), además de tarjetas con indicadores.

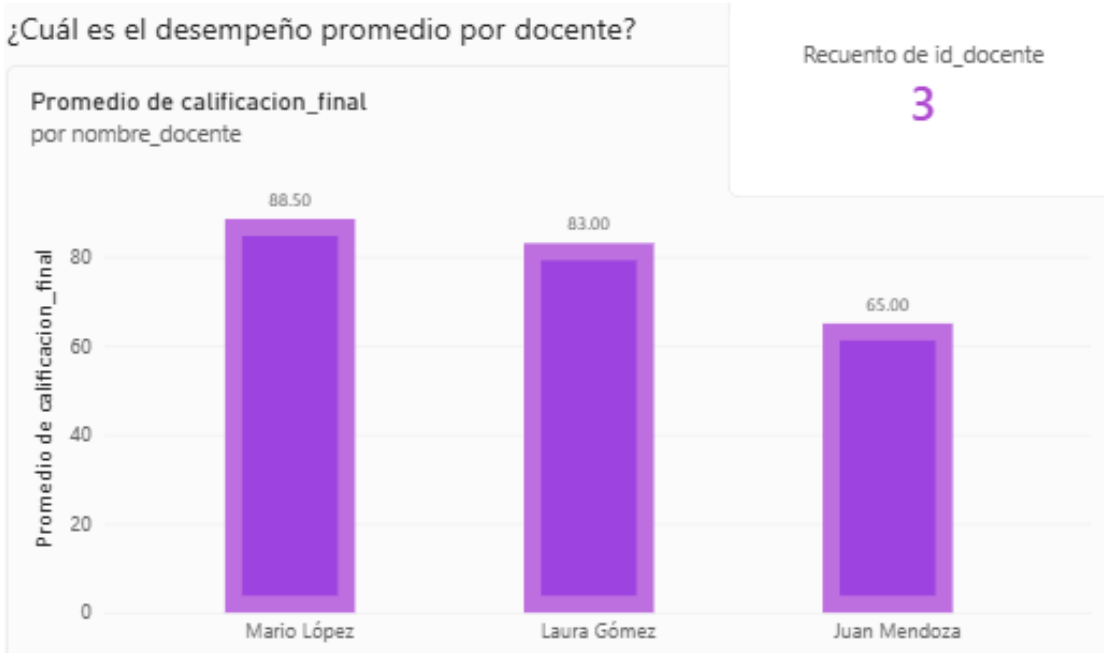
Segmentadores y filtros

Se agregaron segmentadores por materia y por municipio, que filtran todas las gráficas del dashboard al mismo tiempo, para consultar el desempeño de un grupo específico. Cada gráfica recibe además el filtro del contexto de su propio eje (por ejemplo, el promedio por docente se filtra por nombre_docente).

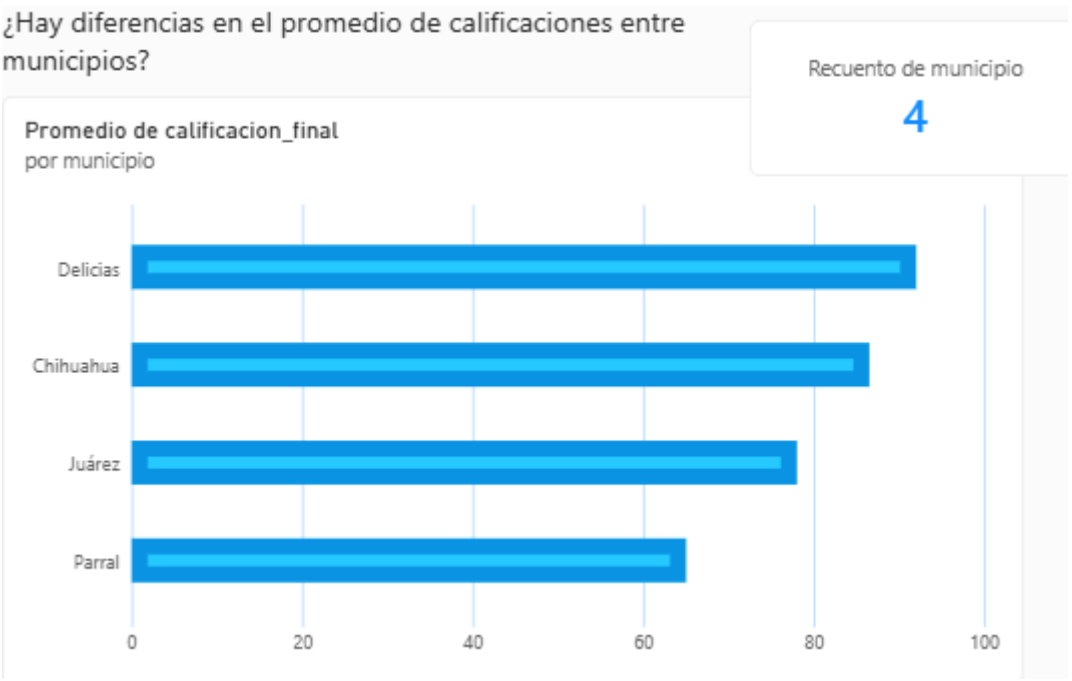
Dashboard que conteste las preguntas del análisis



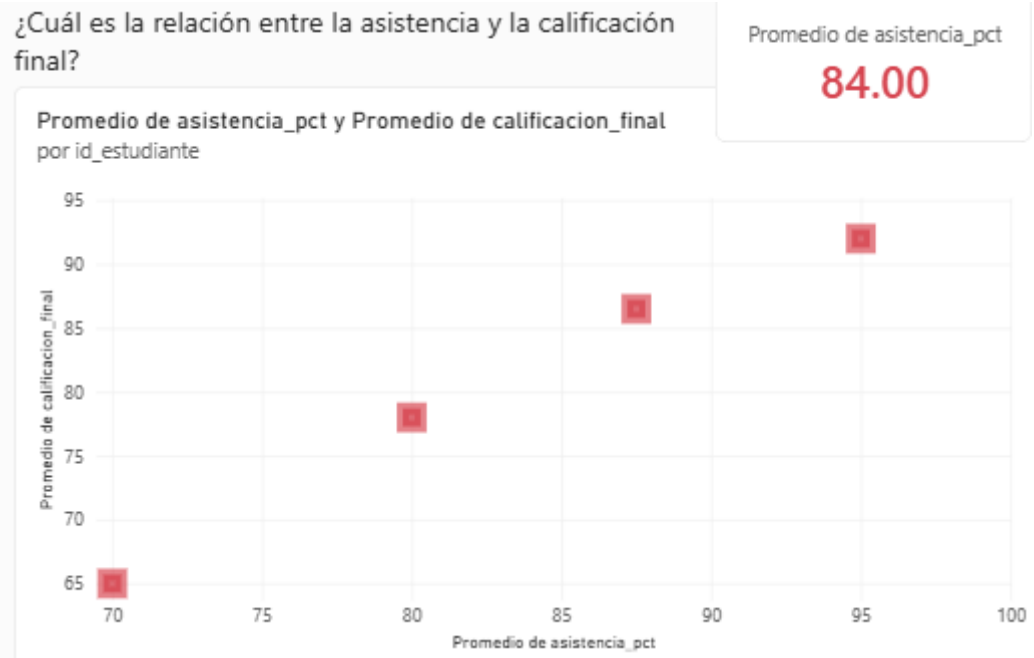
Matemáticas Discretas tiene el promedio más alto (88.5) y Física I el más bajo (65).



Mario López obtuvo un promedio de 88.5, Laura Gómez de 83 y Juan Mendoza de 65



Las diferencias en el promedio de calificaciones entre municipios son Delicias 92, Chihuahua 86.5, Juárez 78 y Parral 65.

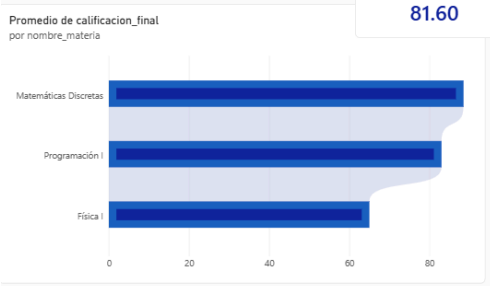


Hay una relación positiva: a mayor asistencia, mayor calificación. Son pocos datos (4 estudiantes), así que es una tendencia y no una conclusión definitiva.

Dashboard-Respuestas de preguntas

¿Cuál es el promedio de calificaciones por materia?

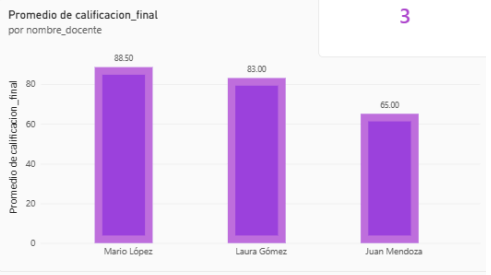
Promedio de calificacion_final
81.60



nombre_materia
- Física I
- Matemáticas Discretas
- Programación I

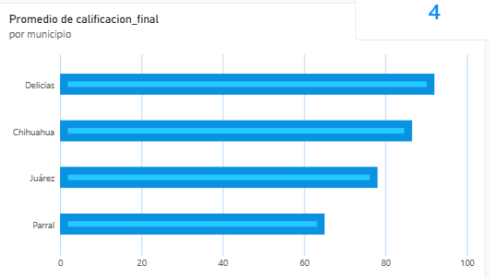
¿Cuál es el desempeño promedio por docente?

Recuento de id_docente
3



¿Hay diferencias en el promedio de calificaciones entre municipios?

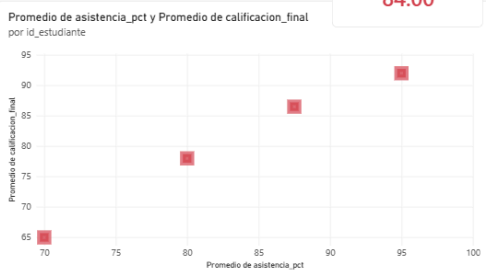
Recuento de municipio
4



municipio
- Chihuahua
- Delicias
- Juárez
- Parral

¿Cuál es la relación entre la asistencia y la calificación final?

Promedio de asistencia_pct
84.00



CONCLUSIÓN

El análisis del dashboard permite responder las preguntas del cliente:

- **Promedio por materia:** el promedio general fue de 81.60. Matemáticas Discretas tuvo el promedio más alto (88.5), seguida de Programación I (83), y Física I el más bajo (65), el único por debajo de 70.
- **Desempeño por docente:** Mario López obtuvo el mejor promedio (88.5), seguido de Laura Gómez (83) y Juan Mendoza (65).
- **Diferencias entre municipios:** sí hay diferencias. Delicias tuvo el promedio más alto (92), luego Chihuahua (86.5), Juárez (78) y Parral el más bajo (65).
- **Asistencia y calificación:** existe una relación positiva. Los estudiantes con más asistencia obtuvieron mejores calificaciones; el promedio de asistencia fue de 84 %.

Hay una limitación importante: el conjunto de datos es una muestra pequeña (5 registros, 4 estudiantes). Los resultados más bajos por materia, por docente y por municipio (Física I, Juan Mendoza y Parral) corresponden al mismo registro, por lo que con estos datos no se puede saber qué factor influye más. Los resultados son una tendencia y no una conclusión definitiva. Con los cinco años de datos que menciona el caso se podrían confirmar estos patrones y analizar la deserción.

En general, el modelo en estrella y el dashboard permiten a la universidad detectar materias con bajo rendimiento, comparar el desempeño docente, identificar diferencias por municipio y ver cómo influye la asistencia en la calificación, para apoyar decisiones de mejora curricular y de reducción de la deserción.